

BGP 多级反射架构路由故障时序分析以及爆炸半径控制方法论探讨




图 1 稳态 topo 图

Topo 描述：

多级 RR 架构，其 client 和非 client ibgp 连接，ebgp 连接，cluster id 如上图所示，Border 从两个 ebgp 邻居收到同一个前缀 A 的两条路由，med 值分别为 50、150。

Router-id 分布：

Cluster-id	Router-id		Cluster-id	Router-id
1.1	1.1.1.1		3.2	6.6.6.6
1.2	2.2.2.2		2.3	8.8.8.8
2.1	3.3.3.3		2.4	9.9.9.9
2.2	4.4.4.4		Border	7.7.7.7

稳态路由（不同色调区分一组主备路由）：

Owner	Best	Router-id	From	Med	Cluster-list
3.2	*	7.7.7.7	Border	50	null
		3.3.3.3	2.1	50	2.1
		4.4.4.4	2.2	50	2.2、2.1
2.1	*	7.7.7.7	Border	50	null
		6.6.6.6	3.2	50	3.2
2.2	*	3.3.3.3	2.1	50	2.1
		6.6.6.6	3.2	50	3.2
		1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
1.1	*	3.3.3.3	2.1	50	2.1
		2.2.2.2	1.2	50	1.2、2.1
1.2	*	3.3.3.3	2.1	50	2.1
		1.1.1.1	1.1	50	1.1、2.1
2.3	*	1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
		9.9.9.9	2.4	50	2.4、1.1、2.1
2.4	*	1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
		8.8.8.8	2.3	50	2.3、1.1、2.1

故障描述：

故障触发是由 Border 连接 Med 50 的链路断开，Border 由于 peer 下一跳不可达，Med 50 优选失效，触发 Med 150 优选，并进一步反射，但由于域内反射路径不一致，并且未合理控制故障爆炸半径，致使到达远端节点完成收敛的过程中，域内始终存在一条 med 50 的通告，致使 Error 节点存在中间态黑洞。





图 2 故障触发示意图

故障收敛时序:

①Step 1:



- Border 向 2.1、3.2 增量更新 med 150 属性路由。
- 2.1 优选 3.2 历史反射的 med 50 的路由。
- 3.2 优选 2.1 历史反射的 med 50 的路由。

瞬时路由变化如下表:

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null
	*	3.3.3.3	2.1	50	2.1
		4.4.4.4	2.2	50	2.2、2.1
2.1		7.7.7.7	Border	150	null
	*	6.6.6.6	3.2	50	3.2
2.2	*	3.3.3.3	2.1	50	2.1
		6.6.6.6	3.2	50	3.2
		1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
1.1	*	3.3.3.3	2.1	50	2.1

		2.2.2.2	1.2	50	1.2、2.1
1.2	*	3.3.3.3	2.1	50	2.1
		1.1.1.1	1.1	50	1.1、2.1
2.3	*	1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
		9.9.9.9	2.4	50	2.4、1.1、2.1
2.4	*	1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
		8.8.8.8	2.3	50	2.3、1.1、2.1

②Step 2:




图 4 step 2 收敛动作

- 2.1 优选路由从 From Border，切换到了 From 3.2，但是 3.2 和 Border 都是 2.1 的 client，因此 RR 反射条件仍成立，该条路由仍被打上 2.1 的 Cluster-id，Cluster-list 变成 (2.1、3.2)，增量更新给 Error、2.2、1.1、1.2。
- 3.2 同时把 From 2.1 的 med 50 路由加上自己的 cluster-id，增量更新给 Error 和 Border。

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null
	*	3.3.3.3	2.1	50	2.1
		4.4.4.4	2.2	50	2.2、2.1
2.1		7.7.7.7	Border	150	null
	*	6.6.6.6	3.2	50	3.2
2.2		3.3.3.3	2.1	50	2.1、3.2
	*	6.6.6.6	3.2	50	3.2
		1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
1.1	*	3.3.3.3	2.1	50	2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1
1.2	*	3.3.3.3	2.1	50	2.1、3.2
		1.1.1.1	1.1	50	1.1、2.1
2.3	*	1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
		9.9.9.9	2.4	50	2.4、1.1、2.1
2.4	*	1.1.1.1	1.1	50	1.1、2.1
		2.2.2.2	1.2	50	1.2、2.1
		8.8.8.8	2.3	50	2.3、1.1、2.1

③Step 3:




图 5 step 3 收敛动作

- 3.2 因为优选的是 From 2.1 的 med 50 路由，之前 adj-out 发送过该 FEC 给 2.1，因此显式对 2.1 发送该 FEC 的 withdraw 撤销更新。
- 3.2 同样因为优选的是 From 2.1 的 med 50 路由，属于非 client 优选，因此要对 2.2 这个非 client 也发送该 FEC 的显式撤销。
- 1.1 和 1.2 之间继续增量更新 2.1 发送过来的 med 50 的路由，1.1、1.2 同时向 2.2、2.3、2.4 增量更新 2.1 发送过来的 med 50 的路由。

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null
	*	3.3.3.3	2.1	50	2.1
		4.4.4.4	2.2	50	2.2、2.1
2.1	*	7.7.7.7	Border	150	null
		6.6.6.6	3.2	50	3.2
2.2	*	3.3.3.3	2.1	50	2.1、3.2
		6.6.6.6	3.2	50	3.2
		1.1.1.1	1.1	50	1.1、2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2
1.1	*	3.3.3.3	2.1	50	2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2

1.2	*	3.3.3.3	2.1	50	2.1、3.2
		1.1.1.1	1.1	50	1.1、2.1、3.2
2.3	*	1.1.1.1	1.1	50	1.1、2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2
		9.9.9.9	2.4	50	2.4、1.1、2.1
2.4	*	1.1.1.1	1.1	50	1.1、2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2
		8.8.8.8	2.3	50	2.3、1.1、2.1

④Step 4:




图6 step 4 收敛动作

- 基于前置收敛, 2.1 优选到了 From Border 的 med 150 的路由, 增量更新给 1.1、1.2、2.2、Error 节点。
- 2.3 和 2.4 相互增量更新残留的 med 50 路由, from 1.1 和 1.2。

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null

		3.3.3.3	2.1	150	2.1
	*	4.4.4.4	2.2	50	2.2、2.1
2.1	*	7.7.7.7	Border	150	null
		6.6.6.6	3.2	50	3.2
2.2		3.3.3.3	2.1	150	2.1
		6.6.6.6	3.2	50	3.2
	*	1.1.1.1	1.1	50	1.1、2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2
1.1		3.3.3.3	2.1	150	2.1
	*	2.2.2.2	1.2	50	1.2、2.1、3.2
1.2		3.3.3.3	2.1	150	2.1
	*	1.1.1.1	1.1	50	1.1、2.1、3.2
2.3	*	1.1.1.1	1.1	50	1.1、2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2
		9.9.9.9	2.4	50	2.4、1.1、2.1、3.2
2.4	*	1.1.1.1	1.1	50	1.1、2.1、3.2
		2.2.2.2	1.2	50	1.2、2.1、3.2
		8.8.8.8	2.3	50	2.3、1.1、2.1、3.2

⑤Step 5:




图 7 step 5 收敛动作

- 1.1、1.2 因优选相互之间发送的 med 50 残留路由，向 2.1、2.2、2.3、2.4 发送增量更新。2.1 因触发 cluster-id 防环，不进入其优选环节。

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null
		3.3.3.3	2.1	150	2.1
	*	4.4.4.4	2.2	50	2.2、2.1
2.1	*	7.7.7.7	Border	150	null
		6.6.6.6	3.2	50	3.2
2.2		3.3.3.3	2.1	150	2.1
		6.6.6.6	3.2	50	3.2
	*	1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
1.1		3.3.3.3	2.1	150	2.1
	*	2.2.2.2	1.2	50	1.2、2.1、3.2
1.2		3.3.3.3	2.1	150	2.1
	*	1.1.1.1	1.1	50	1.1、2.1、3.2
2.3	*	1.1.1.1	1.1	50	1.1、1.2、2.1、3.2

		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
		9.9.9.9	2.4	50	2.4、1.1、2.1、3.2
2.4	*	1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
		8.8.8.8	2.3	50	2.3、1.1、2.1、3.2

⑥Step 6:




图 8 step 6 收敛动作

- 2.1 收到 cluster-list 包含自己的 cluster-id 的前缀路由，不从 adj-in 引入 local-rib 执行优选的同时，向 1.1、1.2 显式发送 withdraw update。
- 2.3、2.4 相互增量更新残留的 med 50 路由。
- 同时由于 1.1、1.2 的 med 150 被 2.1 撤销，依赖的 med 50 更新要发送主动撤销。

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null
		3.3.3.3	2.1	150	2.1

	*	4.4.4.4	2.2	50	2.2、2.1
2.1	*	7.7.7.7	Border	150	null
		6.6.6.6	3.2	50	3.2
2.2		3.3.3.3	2.1	150	2.1
		6.6.6.6	3.2	50	3.2
	*	1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
1.1		3.3.3.3	2.1	150	2.1
		2.2.2.2	1.2	50	1.2、2.1、3.2 （依赖消失主动撤销）
1.2		3.3.3.3	2.1	150	2.1
		1.1.1.1	1.1	50	1.1、2.1、3.2 （依赖消失主动撤销）
2.3	*	1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
		9.9.9.9	2.4	50	2.4、1.1、1.2、2.1、3.2
2.4	*	1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
		8.8.8.8	2.3	50	2.3、1.1、1.2、2.1、3.2

⑦Step 7:




图9 step 7 收敛动作

- 1.1、1.2 因关于 FEC 的所有路由失效，主动发送显式撤销至 2.1、2.2、2.3、2.4。
- 2.3、2.4 类似 step 6 中 1.1、1.2 相互撤销，完成路由清空，此处不再赘述。

Owner	Best	Router-id	From	Med	Cluster-list
3.2		7.7.7.7	Border	150	null
		3.3.3.3	2.1	150	2.1
	*	4.4.4.4	2.2	50	2.2、2.1
2.1	*	7.7.7.7	Border	150	null
		6.6.6.6	3.2	50	3.2
2.2	*	3.3.3.3	2.1	150	2.1
		6.6.6.6	3.2	50	3.2
		1.1.1.1	1.1	50	1.1↖1.2↖2.1↖3.2
		2.2.2.2	1.2	50	1.2↖1.1↖2.1↖3.2
1.1		3.3.3.3	2.1	150	2.1
		2.2.2.2	1.2	50	1.2↖2.1↖3.2（依赖消失主动撤销）

1.2		3.3.3.3	2.1	150	2.1
		1.1.1.1	1.1	50	1.1、2.1、3.2（依赖消失主动撤销）
2.3		1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
		9.9.9.9	2.4	50	2.4、1.1、1.2、2.1、3.2（依赖消失主动撤销）
2.4		1.1.1.1	1.1	50	1.1、1.2、2.1、3.2
		2.2.2.2	1.2	50	1.2、1.1、2.1、3.2
		8.8.8.8	2.3	50	2.3、1.1、1.2、2.1、3.2（依赖消失主动撤销）

⑧Step 8:




图 10 step 8 收敛动作

- 2.1 收到防环显式撤销，重新向 1.1、1.2 更新 med 150 的路由，1.1、1.2 同时向 2.2、2.3、2.4 更新 med 150 路由，1.1、1.2 也相互更新。
- 2.3、2.4 相互触发更新。
- 2.2 优选回归 2.1，触发更新至 3.2。
- 3.2 优选回归 Border，触发更新至 2.1 与 Error 节点。

至此，全域路由完成更新。

Owner	Best	Router-id	From	Med	Cluster-list
3.2	*	7.7.7.7	Border	150	null
		3.3.3.3	2.1	150	2.1
		4.4.4.4	2.2	150	2.2、2.1
2.1	*	7.7.7.7	Border	150	null
		6.6.6.6	3.2	150	3.2
2.2	*	3.3.3.3	2.1	150	2.1
		6.6.6.6	3.2	150	3.2
		1.1.1.1	1.1	150	1.1、2.1
		2.2.2.2	1.2	150	1.2、2.1
1.1	*	3.3.3.3	2.1	150	2.1
		2.2.2.2	1.2	150	1.2、2.1
1.2	*	3.3.3.3	2.1	150	2.1
		1.1.1.1	1.1	150	1.1、2.1
2.3	*	1.1.1.1	1.1	150	1.1、2.1
		2.2.2.2	1.2	150	1.2、2.1
		9.9.9.9	2.4	150	2.4、1.1、2.1
2.4	*	1.1.1.1	1.1	150	1.1、2.1
		2.2.2.2	1.2	150	1.2、2.1
		8.8.8.8	2.3	150	2.3、1.1、2.1

结语：

综合上述的收敛路径，可以看到，从 step1 开始到 step8 结束，Error 节点残留的 med 50 的路由始终优选，如果 BGP 下层存在更复杂的依赖，比如 mpls\路由策略过滤等，则会导致残留路由引发的流量黑洞，全域未更新时，Error 节点的流量持续丢包。

引申思考：

由于这是理想的实验环境复现，现网更有可能的是不同节点，路由量不同，软件版本不同，硬件款型不同，甚至于厂商不同，因此各节点路由收敛快慢区别，厂商版本间对 bgp 路由收敛实现的小差异，会导致收敛过程进一步复杂以及不可预测，进而引发多次流量丢包，路由持续组网中残留的各种二次故障。

因此，合理的控制 BGP 的故障爆炸半径，才是保证组网稳定运行和可预测收敛的核心手段。

以本次故障为例，可通过多种手段把故障爆炸半径控制在一个小的范围，最优情况下可以把故障爆炸的半径控制在源端。以下进行有限列举。

Case 1：（最优推荐）




图 11 Case1 优化示意

- 在 Border 节点对 2.1、3.2 的路由更新的出方向，主动用 route-policy 把这个 FEC 的 med 值修改为 0 或者置为 null，这样 Border 进行优选切换的时候，域内完全无感知。
- 并且该变动为单节点变动，其他节点科室或者人力架构无感知。

Case 2:




图 12 Case2 优化示意

- 若 Border 节点非本端可控域，则可考虑在 2 级 RR 2.1、2.2 向 1.1、1.2 一级 RR 发送路由的时候，进行聚合和抑制明细发送，此时当 med 150 路由从 2.1 增量更新至 2.2 的时候，一级 RR 域内已经完成全域更新，此时 Error 节点优选完毕，可大幅度缩短故障收敛速度和避免后续二次故障的发生。

Case 3:




图 13 Case3 优化示意

- 当整个域为可控域时，对齐域内的路由策略细粒度和 mpls 等底层依赖的启用粒度，同时在 Border 进行 next-hop local，此时底层无论迭代到 med 150 和 med 50，该 FEC 的下一跳都是 Border，如果其底层的 mpls 转发和 IGP 路由转发没有黑洞，则流量也不会受到影响。

综上，合理控制路由故障爆炸半径，要考虑组织架构的可控节点，整个 topo 的透明度（即仅控制该单条路由的爆炸半径，还是从全局出发整体优化）等。进而通过合理利用 BGP 优先级规则，路由过滤策略，community 策略，下一跳修改，以及依赖域内粒度对齐等手段，达成优化的目标。